



Итоговый проект по курсу Machine Learning

Home Credit Default Risk

Коробейников Андрей
Комова Влада
Епифанцев Петр
Истомин Александр

Наша команда



Влада Комова

расскажет про выбор датасета,
исходные данные и задачу



Андрей Коробейников

расскажет про аномалии и фичи



Петр Епифанцев

расскажет про интерпретацию и
выводы



Александр Истомин

подготовил визуализации и
презентацию

Постановка задачи

Цель проекта и бизнес-контекст



01. Суть проекта

Исследовать данные Home Credit о клиентах и их кредитных историях и с помощью методов машинного обучения предсказать клиентов, которые не смогут погасить кредит.



Тип задачи: бинарная классификация



02. Home Credit

Home Credit — кредитная организация, оказывающая услуги в области потребительского кредитования, в первую очередь людям со сравнительно короткой или нулевой кредитной историей.



03. Зачем это нужно

Для снижения кредитных рисков Home Credit использует все известные ей данные для прогнозирования платежеспособности клиентов.



04. Логика решения



Данные
о клиентах



Кредитная
история



ML-модель



Прогноз:
дефолт /
без дефолта

Модель помогает заранее выявлять клиентов с высоким риском невозврата кредита.



Результат

Оценка вероятности
дефолта клиента.

Предсказание кредитного дефолта клиента

Модель оценивает вероятность того, что клиент не сможет выплатить кредит



01. Задача модели

Тип задачи: бинарная классификация



TARGET = 1

Клиент не смог выплатить кредит



TARGET = 0

Клиент успешно погасил кредит



02. Основные таблицы



application_train



307 511 заявок



122 признака



Используется для обучения модели



application_test



48 744 заявки



121 признак



Используется для тестирования модели



Каждая строка в таблицах — одна заявка клиента на получение кредита



03. Какие данные используются



Финансовые данные

Доход клиента, сумма кредита, ежемесячный платёж



Демография

Возраст, пол, семейное положение, количество детей



Занятость

Трудовой стаж, тип занятости, профессия



Имущество

Наличие автомобиля и недвижимости



Внешние скоринги

EXT_SOURCE_1,
EXT_SOURCE_2,
EXT_SOURCE_3



01. Анализ типов признаков

Датасет содержит как числовые, так и категориальные данные

39

целые

65

вещественные

16

категориальные



02. Анализ пропусков

- Некоторые признаки содержат более 60% пропусков
- Особенно много пропусков в признаках недвижимости
- В данных наблюдается «воронка» формирования кредитной заявки: заполненность анкеты зависит от группы клиентов
- Построено распределение количества пропусков по строкам



03. Категориальные признаки

- Выделены бинарные и многоклассовые признаки
- Обнаружены редкие категории — 0,42%



04. Целевой признак и метрика

- В TARGET наблюдается сильный дисбаланс классов — примерно 1:10
- Поэтому в качестве основной метрики качества используется ROC-AUC



05. Связь признаков с TARGET

- Для оценки связи использовался KS-test
- Наибольшую связь с дефолтом показали внешние скоринги: EXT_SOURCE_1, EXT_SOURCE_2, EXT_SOURCE_3




06. Выбросы и важные зависимости


- Для признака DAYS_EMPLOYED обнаружены экстремально большие значения около 350000 — это аномалия, а не реальный стаж
- Чем выше образование клиента, тем ниже вероятность дефолта
- Вероятность дефолта выше у мужчин и у клиентов, проживающих не по месту регистрации



Вероятность дефолта в зависимости от уровня образования



Распределение количества пропусков по строкам



Baseline

Базовая модель и её результат



01. Baseline модель

Random Forest Classifier
class_weight = balanced
max_depth = 10
min_samples_leaf = 2
min_samples_split = 5



02. Подготовка данных

Выполнено заполнение пропусков
и кодирование категориальных признаков




03. Результат

ROC-AUC ≈ 0.73

Модель значительно лучше
случайного классификатора

ROC Curve - Random Forest



ROC-кривая показывает уверенное качество базовой модели
на уровне выше случайного угадывания.

Аномалии

Поиск выбросов и построение признаков аномальности



01. Методы поиска выбросов

- Использованы Z-score, IQR и тест Граббса
- Анализ проводился только на обучающей выборке
- Это позволило избежать утечки данных



02. Признаки аномалий

- Для признаков с большим числом выбросов созданы флаги аномалий
- Также добавлены счетчики выбросов
- Это помогает учитывать нестандартное поведение клиентов



03. Аномалия DAYS_EMPLOYED

- Обнаружены экстремально большие значения, не соответствующие реальному стажу
- Создан бинарный признак DAYS_EMPLOYED_ANOM
- Аномальные значения заменены на nan
- Сохраняется информация об аномалии без искажения распределения



04. Сложные аномалии

- Для многомерного поиска использованы Isolation Forest и LOF
- Методы находят аномальные объекты в пространстве признаков
- Учитывается структура данных, а не только отдельные признаки



05. Краткий вывод

- Anomaly features дали полезное улучшение модели
- Подробное сравнение Isolation Forest и LOF — на следующем слайде



Результат

ROC-AUC после добавления unsupervised anomaly features: **0.74662 ± 0.00291**


- ✓ Добавление признаков аномальности улучшило качество модели

Аномалии: сравнение методов

Isolation Forest и LOF в многомерном пространстве признаков



Isolation Forest




- Доля дефолтов среди выбросов: **0.079666**
- Доля дефолтов среди обычных наблюдений: **0.080762**



Вывод: аномалии Isolation Forest не выглядят сильным риск-сигналом в этой задаче.



Local Outlier Factor (LOF)



- Доля дефолтов среди выбросов: **0.084652**
- Доля дефолтов среди обычных наблюдений: **0.080607**



Вывод: LOF лучше выделяет локально нетипичных и более рискованных клиентов.



Главный вывод

Для поиска сложных аномалий LOF оказался более полезным, чем Isolation Forest.

Итоговое качество модели после добавления unsupervised anomaly features: **ROC-AUC = 0.74662 ± 0.00291**



Анализ выполнялся только на обучающей выборке

Feature Engineering

Генерация признаков и отбор наиболее полезных переменных



01. Категориальные признаки

- Найдено 16 категориальных признаков
- Target encoding показал качество выше, чем one hot encoding
- ROC-AUC: 0.746857 vs 0.746622
- Признаки ближайших соседей дали прирост качества: 0.74662 → 0.74685



02. Временные признаки

- Найдено 6 временных признаков
- Timestamp отсутствует, есть только относительные смещения в днях
- Календарное кодирование не применялось
- Наиболее полезны производные признаки: EMPLOYMENT_AGE_RATIO, REGISTRATION_AGE_RATIO, PHONE_CHANGE_TO_REG_RATIO
- Прирост качества: 0.74685 → 0.74690




03. Контекстные признаки

- Созданы агрегированные признаки: отношение кредита к доходу, отношение аннуитета к доходу, финансовая нагрузка
- На графике видно, что дефолтные клиенты чаще встречаются при относительно низких доходах и высоких суммах кредита относительно дохода



04. Отбор признаков

- После генерации использовалось 140 числовых признаков
- После отбора осталось 40 итоговых признаков
- Методы отбора:
 - ExtraTrees feature importance,
 - статистические фильтры,
 - удаление почти пустых признаков,
 - удаление константных признаков



Топ значимых признаков

- CREDIT_TO_GOODS_RATIO
- CODE_GENDER__te
- REGION_RATING_CLIENT_W_CITY
- EXT_SOURCE_2
- EXT_SOURCE_3
- REGION_RATING_CLIENT
- REGION_POPULATION_RELATIVE
- OCCUPATION_TYPE__te
- FLAG_DOCUMENT_3



Результат

Финальный ROC-AUC после этапа 2: 0.74265 ± 0.00230



Feature engineering позволил улучшить информативность признакового пространства

Интерпретация

Сравнение объяснимости линейной и нелинейной моделей



Лучшая модель по
holdout ROC-AUC: **XGBoost**



01. Выбор моделей


- Logistic Regression — линейная и хорошо объяснимая модель
- XGBoost — нелинейная модель, учитывающая взаимодействия признаков




02. Подход к интерпретации

- Глобальные SHAP-результаты показывают, какие сильнее всего влияют на прогноз
- LIME использован как независимая проверка локальной интерпретации

Logistic Regression



XGBoost



03. Ключевой вывод



Сравнение топ-признаков показывает устойчивость выводов между моделями



Высокое пересечение SHAP и LIME означает стабильные факторы риска



Низкое пересечение указывает на нелинейные зависимости и локальные правила

Интерпретация: локальные объяснения

Сравнение глобальной и локальной интерпретации модели



Лучшая модель по
holdout ROC-AUC: **XGBoost**



01. Что показывают методы

- SHAP показывает глобальное влияние признаков на прогноз
- LIME объясняет отдельные прогнозы через локальную аппроксимацию
- Вместе методы дают более устойчивую интерпретацию

02. Сравнение SHAP и LIME



Высокое пересечение

Ключевые факторы риска стабильны, выводы интерпретации надежны



Низкое пересечение

Модель использует нелинейные зависимости, локальные правила отличаются от глобальной картины



03. Локальное объяснение



Наблюдение с максимальным риском



Прогноз XGBoost



SHAP-вклады



LIME-правила

Для наиболее рискованного клиента отдельно анализируются вклады признаков и локальные правила решения модели.



04. Главный вывод



Лучшей моделью по holdout ROC-AUC стала **XGBoost**



SHAP помогает понять глобальную логику модели



LIME подтверждает или уточняет интерпретацию на уровне конкретного клиента



Глобальная интерпретация + локальная проверка

SHAP embeddings и кластеры

Сегментация клиентов по пространству вкладов признаков модели XGBoost



01. Что такое SHAP embeddings

SHAP embeddings построены как векторы вкладов признаков в прогноз XGBoost. Каждая строка описана не исходными значениями признаков, а тем, как признаки повлияли на индивидуальный прогноз модели.



02. PCA и кластеризация

PCA показал, что SHAP embeddings можно сжать до двух измерений для визуальной диагностики. После этого KMeans выделил 4 кластера клиентов.



03. Риск-профили кластеров

Кластеры существенно различаются по уровню кредитного риска. Наиболее рискованный кластер показывает default rate около 18%, а самый безопасный — менее 3%.



Добавление cluster feature к исходным признакам изменило ROC-AUC: **0.74019 → 0.74175**

SHAP embeddings можно использовать как дополнительный диагностический слой для сегментации клиентов по риску.



4 кластера




max default rate: **18.1%**




min default rate: **2.9%**


Shapley flow proxy graph



KMeans кластеры в пространстве SHAP embeddings



Default Rate by SHAP Cluster



Выводы



01

Постановка задачи

Цель проекта — предсказать риск кредитного дефолта для клиентов Home Credit (бинарная классификация) на основе доступных данных о клиентах и их кредитной истории.



02

EDA

Проведен всесторонний анализ данных: изучены типы признаков, пропуски, распределения, категориальные признаки и целевая переменная. Выявлены ключевые зависимости и аномалии, определены сильные предикторы дефолта.



03

Data Cleaning и обработка аномалий

Выполнена обработка пропусков, кодирование категорий и очистка данных от аномалий. Для учета нестандартного поведения клиентов созданы флаги и счетчики выбросов. Добавление unsupervised anomaly features улучшило ROC-AUC.



04

Feature Engineering

Созданы новые информативные признаки: target encoding, признаки ближайших соседей, производные временные признаки и контекстные финансовые показатели. Проведен отбор признаков, что позволило улучшить качество модели и снизить размерность.



05

Моделирование (Baseline)

Baseline модель на Random Forest показала ROC-AUC ≈ 0.73 , значительно превосходя случайный классификатор и задавая сильную стартовую точку для дальнейших улучшений.



06

Интерпретация

Интерпретация проведена для двух моделей: Logistic Regression и XGBoost. По holdout ROC-AUC лучшей моделью стала XGBoost. Анализ SHAP и LIME показал устойчивые ключевые признаки риска.



07

SHAP embeddings и кластеры

SHAP embeddings позволили сегментировать клиентов на группы с разным уровнем риска. Кластеры демонстрируют существенные различия в доле дефолтов и улучшают ROC-AUC при добавлении в модель.



Итог

Построена эффективная модель на XGBoost с учетом инженерии признаков, обработки аномалий и интерпретации. Модель способна надежно предсказывать риск дефолта и обеспечивает бизнесу обоснованный инструмент для принятия кредитных решений.